

2016-2017 学年秋季学期 试题专用纸

中国科学院大学

试题专用纸

课程编号: 091M4042H


课程名称: 模式识别与机器学习

任课教师: 黄庆明、山世光、兰艳艳、郭嘉丰

注意事项:

1. 考试时间为 120 分钟, 考试方式 闭卷;
2. 全部答案写在答题纸上;
3. 考试结束后, 请将本试卷和答题纸、草稿纸一并交回。

1. (6分) 简述模式的概念和它的直观特性, 并简要说明模式分类有哪几种主要方法。
2. (8分) 假设某研究者在 ImageNet 数据上使用线性支持向量机 (Linear SVM) 来做文本分类的任务, 请说明在如下情况下分别如何操作才能得到更好的结果, 并说明原因。
 - (1) 训练误差5%, 验证误差10%, 测试误差10%。
 - (2) 训练误差1%, 验证误差10%, 测试误差10%。
 - (3) 训练误差1%, 验证误差3%, 测试误差10%。
3. (8分) 给定如下概率图模型, 其中变量 X_3 为已观测变量, 请问变量 X_1 和 X_6 是否独立? 并用概率推导证明之。



4. (10分) (1) 随机猜测作为一个分类算法是否一定比 SVM 差? 借此阐述你对 “No Free Lunch Theorem” 的理解。(2) 举例阐述你对 “Occam’s razor” 的理解。
5. (10分) 详细描述 AdaBoost 的原理并给出算法, 并解释为什么 AdaBoost 经常可以在训练误差为 0 后继续训练还可能带来测试误差的继续下降。
6. (10分) 用感知器算法求下列模式分类的解向量 (取 $w(1)$ 为零向量)
 $\omega_1: \{(0\ 0\ 0)^T, (1\ 0\ 0)^T, (1\ 0\ 1)^T, (1\ 1\ 0)^T\}$
 $\omega_2: \{(0\ 0\ 1)^T, (0\ 1\ 1)^T, (0\ 1\ 0)^T, (1\ 1\ 1)^T\}$

7. (12 分) 设以下模式类别具有正态概率密度函数:

$$\omega_1: \{(0 \ 0 \ 0)^T, (1 \ 0 \ 0)^T, (1 \ 0 \ 1)^T, (1 \ 1 \ 0)^T\}$$

$$\omega_2: \{(0 \ 1 \ 0)^T, (0 \ 1 \ 1)^T, (0 \ 0 \ 1)^T, (1 \ 1 \ 1)^T\}$$

若 $P(\omega_1)=P(\omega_2)=0.5$, 求这两类模式之间的贝叶斯判别界面的方程式。

8. (12 分) 假设有如下线性回归问题,

$$\min_{\beta} (y - X\beta)^2 + \lambda \|\beta\|_2^2$$

其中 y 和 β 是 n 维向量, X 是一个 $m \times n$ 的矩阵。

该线性回归问题的参数估计可看作一个后验分布的均值, 其先验为高斯分布 $\beta \sim N(0, \tau I)$, 样本产生自高斯分布 $y \sim N(X\beta, \sigma^2 I)$, 其中 I 为单位矩阵, 试推导调控系数 λ 与方差 τ 和 σ^2 的关系。

9. (12 分) 给定有标记样本集 $D_l = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$ 和未标记样本 $D_u = \{(x_{l+1}, y_{l+1}), (x_{l+2}, y_{l+2}), \dots, (x_{l+u}, y_{l+u})\}$, $l \ll u$, $l + u = m$, 假设所有样本独立同分布, 且都是由同一个包含 N 个混合成分的高斯混合模型 $\{(\alpha_i, \mu_i, \Sigma_i) | 1 \leq i \leq N\}$ 产生, 每个高斯混合成分对应一个类别, 请写出极大似然估计的目标函数 (对数似然函数), 以及用 EM 算法求解参数的迭代更新式。

10. (12 分) 假定对一类特定人群进行某种疾病检查, 正常人以 ω_1 类代表, 患病者以 ω_2 类代表。设被检查的人中正常者和患病者的先验概率分别为

$$\text{正常人: } P(\omega_1)=0.9$$

$$\text{患病者: } P(\omega_2)=0.1$$

现有一被检查者, 其观察值为 x , 从类条件概率密度分布曲线上查得

$$P(x | \omega_1)=0.2, P(x | \omega_2)=0.4$$

同时已知风险损失函数为

$$\begin{pmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{21} & \lambda_{22} \end{pmatrix} = \begin{pmatrix} 0 & 6 \\ 1 & 0 \end{pmatrix}$$

其中 λ_{ij} 表示将本应属于第 j 类的模式判为属于第 i 类所带来的风险损失。试对该被检查者用以下两种方法进行分类:

- (1) 基于最小错误率的贝叶斯决策, 并写出其判别函数和决策面方程;
- (2) 基于最小风险的贝叶斯决策, 并写出其判别函数和决策面方程。

2016-2017

1. 模式是抽取自物体的信息集合, 既包含空间部分, 又包含时间部分.

直观特性: 可观察性, 可区分性, 相似性

主要方法: 监督学习: 概念驱动, 归纳假设

非监督学习: 数据驱动, 演绎假设

2. (1) 欠拟合, 换用复杂度更高的模型

(2) 过拟合, 换用复杂度更低的模型

(3) 测试数据与训练数据不是独立同分布的, 更换测试数据集

4. (1) 不一定, 在无先验知识的情况下, 无法断言一个模型比另一个更好.

对特定的问题为了获得更好的效果需要仅用更复杂的模型.

(2) 训练数据来自添加高斯噪声的 $y = \sin x$ ($x \in [0, 2\pi]$).

使用不同的多项式函数拟合, 三次的效果最佳. 在同等错误

率的条件, 简单模型具有更小的方差, 更好的泛化能力.

5. $\{x_i, y_i\}_{i=1}^n$

$$D(i) = \frac{1}{n}$$

for 1 to T:

训练弱分类器 k_i

$$D(i+1) = D(i) \cdot e^{-\alpha_i y_i h_i(x_i)}$$

通过弱分类器的组合, 得到强分类器.

每次训练弱分类器后, 对分类错误的

样本, 增加权重使得后续的分类器

更加“关注”该样本, 以期提升

分类效果的目的.

其中 $\alpha_i = \frac{1}{2} \ln \frac{1-\epsilon}{\epsilon}$, $\epsilon = P(h(x) \neq y) < 0.5$

$$H_{\text{final}} = \sum \alpha_i h_i(x)$$

当训练误差为零后, AdaBoost 会继续增大

分类间隔, 提升模型的泛化能力, 减少测试误差.

6. $W(1) = (0, 0, 0, 0)^T$, 对 W_2 的样本取相反数

增加数据: $W_1 = \{(0, 0, 0, 1)^T, (1, 0, 0, 0)^T, (0, 1, 1)^T, (1, 1, 0, 1)^T\}$

$W_2 = \{(0, 0, -1, -1)^T, (-0, -1, -1, 1)^T, (-0, 1, 0, 1)^T, (-1, -1, 1, 1)^T\}$

更新规则: $W(k+1) = \begin{cases} W(k) & W(k)^T X(k) > 0 \\ W(k) + X(k+1) & \text{其它} \end{cases}$ (以下省略不更新的步骤)

$X(1) = (0, 0, 0, 1)^T$, $W(1)^T X(1) = 0$ 更新: $W(2) = (0, 0, 0, 1)^T$

$X(2) = (0, 0, -1, -1)^T$, $W(2)^T X(2) = -1$ 更新: $W(3) = (0, 0, -1, 0)^T$

$X(3) = (0, 1, 0, -1)^T$, $W(3)^T X(3) = 0$ 更新: $W(4) = (0, -1, -1, -1)^T$

$X(4) = (0, 0, 0, 1)^T$, $W(4)^T X(4) = -1$, 更新: $W(5) = (0, -1, -1, 0)^T$

$X(5) = (1, 0, 0, 1)^T$, $W(5)^T X(5) = 0$, 更新: $W(6) = (1, -1, -1, 1)^T$

$X(6) = (0, 0, -1, -1)^T$, $W(6)^T X(6) = 0$, 更新: $W(7) = (1, -1, -2, 0)^T$

$X(7) = (0, 0, 0, 1)^T$, $W(7)^T X(7) = 0$, 更新: $W(8) = (1, -1, -2, 1)^T$

$X(8) = (1, 0, 1, 1)^T$, $W(8)^T X(8) = 0$, 更新: $W(9) = (2, -1, -1, 2)^T$

$X(9) = (0, 0, -1, -1)^T$, $W(9)^T X(9) = -1$, 更新: $W(10) = (2, -1, -2, 1)^T$

$X(10) = (0, -1, 0, -1)^T$, $W(10)^T X(10) = 0$, 更新: $W(11) = (2, -2, -2, 0)^T$

$X(11) = (0, 0, 0, 1)^T$, $W(11)^T X(11) = 0$, 更新: $W(12) = (2, -2, -2, 1)^T$

$W = W(12) = (2, -2, -2, 1)^T$

$$7. p(w_1|x) = \frac{p(x|w_1)p(w_1)}{p(x)}$$

$$p(w_2|x) = \frac{p(x|w_2)p(w_2)}{p(x)}$$

$$p(w_1|x) > p(w_2|x)$$

$$p(x|w_1)p(w_1) > p(x|w_2)p(w_2)$$

$$\frac{p(x|w_1)}{p(x|w_2)} - \frac{p(w_2)}{p(w_1)} > 0$$

$$d(x) = \frac{p(x|w_1)}{p(x|w_2)} - \frac{p(w_2)}{p(w_1)} = \frac{p(x|w_1)}{p(x|w_2)} - 1 = 0$$

假设给定 w 的情况下, x 的各分量相互独立.

$$p(x|w) = p(x_1, x_2, x_3|w) = p(x_1|w)p(x_2|w)p(x_3|w)$$

$$d(x) = \frac{\prod_{i=1}^3 p(x_i|w_1)}{\prod_{i=1}^3 p(x_i|w_2)} - 1 = 0$$

8.

$$p(\vec{\beta} | \vec{y}) = \frac{p(\vec{y} | \vec{\beta}, \vec{x}, \sigma) \cdot p(\vec{\beta} | r)}{p(\vec{y})}$$

对数似然: $\log p(\vec{\beta} | \vec{y}) = \log p(\vec{y} | \vec{\beta}, \vec{x}, \sigma) + \log p(\vec{\beta} | r) - \log p(\vec{y})$

$$= \log \prod_{i=1}^n p(y_i | \vec{\beta}, \vec{x}_i, \sigma) + \log \frac{1}{\sqrt{2\pi|\Sigma|}} \cdot e^{-\frac{1}{2}(\vec{\beta} - \vec{0})^T (\Sigma^{-1}) (\vec{\beta} - \vec{0})} - \log p(\vec{y})$$

$$= \sum_{i=1}^n \log \frac{1}{\sqrt{2\pi|\Sigma|}} e^{-\frac{1}{2}(y_i - \vec{x}_i^T \vec{\beta}) (\Sigma^{-1}) (y_i - \vec{x}_i^T \vec{\beta})} + \left(-\frac{1}{2} \vec{\beta}^T (\Sigma^{-1}) \vec{\beta} \right) + \text{constant}$$

$$= \sum_{i=1}^n -\frac{1}{2} (y_i - \vec{x}_i^T \vec{\beta})^T (\Sigma^{-1}) (y_i - \vec{x}_i^T \vec{\beta}) - \frac{1}{2} \vec{\beta}^T (\Sigma^{-1}) \vec{\beta} + \text{constant}$$

$$= \sum_{i=1}^n -\frac{1}{2} \cdot \frac{1}{\sigma^2} (y_i - \vec{x}_i^T \vec{\beta})^T (y_i - \vec{x}_i^T \vec{\beta}) - \frac{1}{2} \cdot \frac{1}{\sigma^2} \vec{\beta}^T \vec{\beta} + C$$

$$= -\frac{1}{2\sigma^2} (y - X\beta)^2 - \frac{1}{2\sigma^2} \|\beta\|^2 + C$$

$$= -\frac{1}{2\sigma^2} \left[(y - X\beta)^2 + \frac{\sigma^2}{\sigma^2} \|\beta\|^2 \right] + C$$

$$\max \log p(\vec{\beta} | \vec{y}) \iff \min (y - X\beta)^2 + \frac{\sigma^2}{\sigma^2} \|\beta\|^2 \quad \therefore \lambda = \frac{\sigma^2}{\sigma^2}$$

9. $D_1 = \{(x_i, y_i)\}_{i=1}^L$ 已知, $D_2 = \{(x_i, y_i)\}_{i=L+1}^m$ 未知

令 $z_{ik} = \mathbb{I}(x_i, y_i = k)$, $\forall i, 1 \leq i \leq m$, 且 $z_{ik} \sim B(1, p(y_i = k | x_i))$.

E-step: $E(z_{ik}) = p(y_i = k | x_i) = \frac{p(x_i | y_i = k) p(y_i = k)}{p(x_i)} = \frac{p(x_i | y_i = k) p(y_i = k)}{\sum_{j=1}^n p(x_i | y_i = j) p(y_i = j)}$

M-step: $\prod_{i=1}^m p(x_i, y_i) = \prod_{i=1}^L p(x_i, y_i) \cdot \prod_{i=L+1}^m p(x_i, y_i)$

$$\forall i, 1 \leq i \leq m \quad p(x_i, y_i) = \prod_{j=1}^n p(x_i, y_i = j)^{z_{ij}}$$

$$\prod_{i=1}^m p(x_i, y_i) = \prod_{i=1}^L p(x_i, y_i) \cdot \prod_{i=L+1}^m \prod_{j=1}^n p(x_i, y_i = j)^{z_{ij}}$$

对数似然: $\sum_{i=1}^L \log p(x_i, y_i) + \sum_{i=L+1}^m \sum_{j=1}^n z_{ij} (\log p(x_i | y_i = j) + \log p(y_i = j))$

$$= \sum_{i=1}^L \left(\log p(x_i) + \log p(y_i) \right) + \sum_{i=L+1}^m \sum_{j=1}^n z_{ij} \left(-\frac{1}{2} (x_i - \mu_j)^T \Sigma^{-1} (x_i - \mu_j) + \log p(y_i = j) \right) + \text{constant}$$

$$\mu_j = \frac{\sum_{i=1}^L x_i \mathbb{I}(y_i = j)}{\sum_{i=1}^L \mathbb{I}(y_i = j)} + \frac{\sum_{i=L+1}^m x_i \cdot z_{ij}}{\sum_{i=L+1}^m z_{ij}} \quad \Sigma_j = \frac{1}{\sum_{i=1}^L \mathbb{I}(y_i = j)} \sum_{i=1}^L (x_i - \mu_j)^2 \mathbb{I}(y_i = j) + \frac{1}{\sum_{i=L+1}^m z_{ij}} \sum_{i=L+1}^m (x_i - \mu_j)^2 \cdot z_{ij}$$

$$p(y_i = j) = \frac{\sum_{i=1}^L \mathbb{I}(y_i = j)}{L} + \frac{\sum_{i=L+1}^m z_{ij}}{m-L}$$

2018-1-19 22:14

$$10. (1) \quad p(w_1|x) = \frac{p(x|w_1) \cdot p(w_1)}{p(x)}$$

$$p(w_2|x) = \frac{p(x|w_2) \cdot p(w_2)}{p(x)}$$

$$p(w_1|x) > p(w_2|x)$$

$$p(x|w_1)p(w_1) > p(x|w_2)p(w_2)$$

$$\frac{p(x|w_1)}{p(x|w_2)} - \frac{p(w_2)}{p(w_1)} > 0$$

$$d(x) = \frac{p(x|w_1)}{p(x|w_2)} - \frac{p(w_1)}{p(w_2)} = 0$$

$$d(x) = \frac{0.2}{0.4} - \frac{0.9}{0.1} = -7 < 0$$

$$\therefore x \in w_2$$

$$(2) \quad r_1 = L_{11} \cdot p(x, w_1) + L_{12} \cdot p(x, w_2)$$

$$= 0 \cdot p(x|w_1)p(w_1) + 6 \cdot p(x|w_2)p(w_2)$$

$$= 0 + 6 \times 0.4 \times 0.1$$

$$= 0.24$$

$$r_2 = 0.18 < 0.24 = r_1$$

$$\therefore x \in w_2$$

$$r_2 = L_{22} \cdot p(x, w_2) + L_{21} \cdot p(x, w_1)$$

$$= 0 \cdot p(x|w_2)p(w_2) + 1 \times p(x|w_1)p(w_1)$$

$$= 0 + 1 \times 0.2 \times 0.9$$

$$= 0.18$$